

## F-AG 7: Angewandte Sprachwissenschaft, Computerlinguistik Kurationsprojekt 2

Linguistische Annotation von Nichtstandardvarietäten — Guidelines und "Best Practices"

## **Guidelines NER**

Version 1.6 Stand: 20.10.13

Marc Reznicek
Burkhard Dieterle
Darina Benikova



#### Kafka@WebAnno

Guidelines für die Named Entity Recognition. Sie bauen auf den Guidelines in den <u>STTS-Guidelines (Schiller et al. 1999)</u>, dem <u>Stylebook for Tübingen Treebank (Telljohann et al. 2012)</u> und der MUC-6 Named Entity Task Definition auf.

### **Inhalt**

<u>Inhalt2</u>
Einführung: Named Entity Recognition
Wie finde ich eine NE?3
Zu welcher semantischen Klasse gehört ein Eigenname?5
Wie finde ich Ableitungen von NEs?5
Zu welcher semantischen Klasse gehört eine Ableitung?6
Faustregel zur Unterscheidung einer Klassenbezeichnung und eines Namens6
NoSta-D-TagSet6
Bibliografie
Beispiele

## **Einführung: Named Entity Recognition**

Unter der Named Entity Recognition (NER) versteht man die Aufgabe, Eigennamen (named entities) in Texten zu erkennen. Technisch gesehen sind hierzu zwei Schritte notwendig. Zuerst müssen in einem laufenden Text die Token gefunden werden, die zu einem Eigennamen gehören (Named Entity Detection: NED), danach können diese Eigennamen semantischen Kategorien zugeordnet werden (Named Entity Classification).

Prototypisch ist dabei der Unterschied zwischen **Eigennamen** und **Appellativa** der, dass letztere eine Gattung oder eine Klasse beschreiben, während erstere einzelne Individuen oder Sammlungen von Individuen unabhängig von gemeinsamen Eigenschaften bezeichnen (Gallmann 2009:149).

Die vorliegenden Guidelines sollen es Annotatoren ermöglichen, Eigennamen in Texte aus Standard und Nichtstandard-Varietäten konsistent zu annotieren.

In diesen Guidelines werden die beiden Aufgaben der NED und NEC nicht unterschieden, da die Konzentration auf Beispiele in diesem Dokument, die Trennung künstlich erzeugen müsste und nicht zu erwarten ist, dass die Resultate sich dadurch verbessern würden.

In Anlehnung an die oben genannten Guidelines für Zeitungssprache werden in <u>NoSta-D</u> vier semantische Hauptklassen unterschieden (Personen, Organisationen, Orte und Andere). Diese werden teilweise um spezifische Verwendungen erweitert (virtuelle Orte), Eigennamen, die Teile größerer Einheiten sind, werden als solche markiert (NEpart), oder Appellativa, die von Eigennamen abgeleitet sind, werden gesondert behandelt (NEderiv).

#### Wie finde ich eine NE?

#### Schritt 1:

➤ Nur **volle Nominalphrasen** können **NEs** sein. Pronomen und alle anderen Phrasen können ignoriert werden.

#### Schritt 2:

Namen sind im Prinzip Bezeichnungen für einzigartige Einheiten, die nicht über gemeinsame Eigenschaften beschrieben werden.

#### **Beispiel:**

[Der Struppi] folgt [seinem Herrchen].

- ➤ Hier gibt es zwei Nominalphrasen als Kandidaten für einen Eigennamen (NE).
- ➤ "Der Struppi" bezeichnet eine einzige Einheit. Es kann auch mehrere Struppis geben, aber diese haben an sich keine gemeinsamen Eigenschaften, bis auf den gemeinsamen Namen, daher handelt es sich um einen Eigennamen.
- ➤ "seinem Herrchen" bezeichnet zwar (typischerweise) auch nur eine einzige Person allerdings können wir diese nur über die Eigenschaft identifizieren, dass sie ein Herrchen ist und dass dies für Struppi zutrifft. Struppi könnte auch mehrere Herrchen haben, die alle die Eigenschaften teilen, die ein Struppi-Herrchen beinhaltet (z.B. darf Struppi streicheln, muss ihn ausführen und füttern etc.)

#### **Schritt 3:**

> Determinierer sind keine Teile des Namens.

Der [Struppi]NE folgt seinem Herrchen.

#### Schritt 4:

Eigennamen können mehr als ein Token beinhalten.

#### **Beispiel:**

Viele Personennamen (PER für person):

[Peter Müller]PER

Filmtitel (OTH für *other*):

[Knockin' on Heavens Door]OTH

#### **Schritt 5:**

Eigennamen können auch ineinander verschachtelt sein.

#### **Beispiel:**

Personennamen in Filmtiteln:

[[Shakespeare]PER in Love]OTH

Orte (LOC für *location*) in Vereinsnamen (ORG für *organisation*):

[SV [Werder [Bremen]LOC]ORG]ORG

#### Schritt 6:

➤ **Titel**, **Anreden** und **Besitzer** gehören **NICHT** zu einem komplexen Eigennamen. Besitzer können natürlich selber Eigennamen sein.

#### **Beispiel:**

#### **Referenz auf Musiktitel:**

#### [Vivaldis]PER [Vier Jahreszeiten]OTH

#### **Referenz auf Personen:**

Landesvorsitzende Frau [Ute Wedemeier]PER

#### Schritt 7:

Eigennamen treten auch als **Teil eines komplexen Tokens** auf. Hier wird für das gesamte Token annotiert, dass es einen Eigennamen enthält.

#### **Beispiel:**

mit Firmen Assoziiertes:

[DAEWOO-Millionen]ORGpart

mit bestimmten Personen verbundene Erfindungen/Arbeiten:

[Hartz-Reformen]PERpart

[Ottomotor]PERpart

#### **ABER:**

➤ Wenn auch das Gesamttoken einen Eigennamen darstellt, dann wird nur dieser annotiert.

#### **Beispiel:**

Stiftungen:

[Böll-Stiftung]ORG

#### **Schritt 8:**

➤ Kann in einem Kontext nicht entschieden werden, ob eine NP sich als Eigennamen oder Appellativ verhält, wird es nicht als NE markiert.

#### **Beispiel:**

Ortsnamen vs. -beschreibungen:

...und zogen mit ihren großen Transparenten gestern vom [Steintor] über den [Ostertorsteinweg]LOC zum [Marktplatz].

#### Schritt 9:

➤ Wenn ein Name als Bezeichnung für bestimmte Gegenstände in die Sprache übergegangen ist und in seiner Nutzung nicht als **NE** fungiert, so wird dieser nicht annotiert.

#### **Beispiel:**

[Teddybär] **\*** (NICHT **PER**deriv)

[Colt] **\*** (NICHT **PER**deriv)

#### Schritt 10:

➤ Bei Aufzählungen mit Hilfe von Bindestrichen oder Vertragen eines Teils der NE auf spätere Wörter, wird die NE so annotiert, als sei sie voll ausgeschrieben.

#### **Beispiel:**

[Erster]OTH und [Zweiter Weltkrieg]OTH [Süd-]LOC und [Nordkorea] LOC

## Zu welcher semantischen Klasse gehört ein Eigenname?

- ➤ Wenn der Namenskandidat in der Liste unter der Klasse "**keine NE**" aufgeführt wird, dann handelt es sich nicht um eine NE im Sinne dieser Guidelines.
- Wenn der Eigenname in eine der Klassen in der Liste Faustregel zur Unterscheidung einer

Klassenbezeichnung und eines Namens gehört, dann annotiere die zugehörige Klasse.

- > Sollte die gefundene NE Rechtschreibfehler enthalten, wird sie dennoch annotiert
- ➤ In Zweifelsfällen hilft auch die Tabelle **NoSta-D-TagSet** und alle Untertabellen, insbesondere die Beispiele mit dem **\*** weiter.
- ➤ Wenn nicht klar ersichtlich ist, ob eine NE NEderiv oder NEpart ist, weil sie beiden Klassen zugeordnet werden könnte, gilt folgende Regel: Steht eine vollständige NE in der Phrase, so ist wird es NEpart zugeordnet, ansonsten NEderiv.

#### **Beispiel:**

#### [deutschlandweit]LOCpart [norddeutsche]LOCderiv Stämme

➤ Wenn eine Kombination aus NEderiv und NEpart auftritt, so wird die Klassifizierung nach der ersten NE gemacht.

#### **Beispiel:**

#### [Linke-Europaabgeordnete]ORGpart

➤ Jahreszahlen in ORGanisationen werden nicht markiert.

#### **Beispiel:**

[Fußball-WM]ORG 2006 [Eurovision Song Contest] 2013

➤ Wenn der Eigennamen in **KEINE** der vorhandenen Klassen passt, dann markieren ihn mit \*\*\*UNCLEAR\*\*\* und notiere Dir bitte das Beispiel und schicke uns eine E-Mail an: marc.reznicek@staff.hu-berlin.de. So können wir die Guidelines sukzessive verbessern.

### Wie finde ich Ableitungen von NEs?

#### **Schritt 1:**

➤ Eigennamen, die durch morphologische Derivation in andere Wortarten überführt wurden, werden als solche markiert. NEderivs müssen keine vollen Nominalphrasen sein. Deklination in diesen Guidelines nicht als Derivation angesehen und deshalb als direkte NE annotiert.

#### **Beispiel:**

#### Ortsadjektive:

die [Bremer]LOCderiv Staatsanwaltschaft

#### Personenadjektive:

die [Merkelsche]PERderiv Begeisterung für Europa

#### aber:

#### **Genitive:**

[Deutschlands] LOC beste Fußballspieler

### Zu welcher semantischen Klasse gehört eine Ableitung?

➤ Die Klasse setzt sich aus dem Tag der Klasse zusammen, in die der ursprüngliche Eigennamen gehört und dem Marker für die Ableitung "deriv".

#### **Beispiel:**

Ortsadjektive:

 $[Bremen] \rightarrow LOC$ 

die [Bremer]LOCderiv Staatsanwaltschaft

# Faustregel zur Unterscheidung einer Klassenbezeichnung und eines Namens

#### Faustregel zur Unterscheidung einer Klassenbezeichnung und eines Namens:

- Elemente der fraglichen Einheit verbinden die gleichen Eigenschaften → Klasse →keine NE
- Christen glauben an Christus → Christ glaubt an Christus → keine NE
- Die Elemente der fraglichen Einheit verbindet nur der Name oder Element ist Einheit bezeichnet ein spezifisches Individuum → Name → NE
- Barock bezeichnet spezifische Epoche

**ABER:** die [Deutschen]**LOCderiv** 

## NoSta-D-TagSet

Semantische Klasse	Semantische Subklasse	Beispiele	Ausnahmen
	Person	Hans Winkler	_
	Zuname	(Familie) Feuerstein	
	Tiernamen	(Schweinchen) Babe	
PER - Person	Künstlernamen	Madonna	_
	Charaktere	Schneewitchen, Miss Piggy	_
	Nicknames	Sternchen333	
	Superhelden	Batman	
ORG - Organisation	Organisationen	Nato, EU, Landgericht Darmstadt, Bundesverwaltungsgericht,Weimarer Republik	<del>Parlament</del>
	Unternehmen	Microsoft, Bertelsmann	_
	Flughäfen	Fraport	Frankfurter Flughafen
	Betreiber	Lotto 6 aus 49	
	Institute	Institut für chinesische Medizin	_
	Museen	Pergamonmuseum	
	Zeitungen	Süddeutsche Zeitung, Der Spiegel	_
	Clubs	VfB Stuttgart	
	Theater, Kinos	Metropol-Theater, CinemaxX	
	Festivals	Eurovision Song Contest	_
Austellungen		Körperwelten	_
	Universitäten	Technische Universität Darmstadt	
	Rundfunksender	Arte, Radio Bremen	_
	Restaurants und Hotels	Sassella, Adlon	

	Militäreinheiten	Blauhelme	-
	Krankenhäuser, Pflegeheime	Charité, Klinikum Ingolstadt	-
	Modelabels	Chanel	
	Sportereignisse	Olympische Spiele, Wimbledon	
	Festspiele	Berlinale	
	Bands	Beatles, Die Fantastischen Vier	
	Institution	Bundestag	
	Bibliotheken	Amerika Gedenkbibliothek	
	Parteien	SPD, CDU	
	Bezirke	Schöneberg Schöneberg	
	Sehenswürdigkeiten, Kirchen	Brandenburger Tor, Johanniskirche	
	Planeten	Mars	
	Landschafts-bezeichnungen	Königsheide	-
	Straßen, Plätze	Söogestraße, Alexanderplatz, A 5	
LOC - Ort	Einkaufszentren	Luisencenter, Allee-Center	
LOC - OIT	Berge, Seen, Flüsse	Alpen, Viktoriasee, Spree	
	Kontinente	Europa, Asien	
	Länder, Staaten	Frankreich, Hessen, Assyrien, USA	
	Städte	Berlin, Babylon	•
		•	_
	Regionen	Gazastreifen	Wenn
LOCderiv - Ortsableitungen	Wettbewerbe	Deutsche (Meisterschaft)	spezifisch, dann ORG.
	Betriebssysteme	DOS	
	Detricossysteme	D05	_
	Buch-, Filmtitel etc.	Faust, Schlaflos in Seattle	
	Buch-, Filmtitel etc.	Faust, Schlaflos in Seattle	
	Buch-, Filmtitel etc. Kriege	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen	
	Buch-, Filmtitel etc. Kriege Politische Aktionen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung	
	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen Sprachen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein Helbig et al. ([Helbig]_PER et al.)OTH	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein Helbig et al. ([Helbig] <sub>PER</sub> et al.) <sub>OTH</sub> Mensch-ärgere-dich-nicht, Halo	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele Kunstwerke	Faust, Schlaflos in Seattle  Zweiter Weltkrieg  7. Bremer Protesttag gegen Diskriminierung  Agenda 21  Euro  Dow Jones, Dax  SZ-Magazin 41/07  Deutsch, Latein  Helbig et al. ([Helbig] <sub>PER</sub> et al.) <sub>OTH</sub> Mensch-ärgere-dich-nicht, Halo  Mona-Lisa  Barock, Romantik (auch Neubildungen:	
OTH - Andere	Buch-, Filmtitel etc. Kriege Politische Aktionen Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele Kunstwerke Epochen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein Helbig et al. ([Helbig]_PER et al.)OTH Mensch-ärgere-dich-nicht, Halo Mona-Lisa Barock, Romantik (auch Neubildungen: "Neuzeit"))	
OTHderiv –	Buch-, Filmtitel etc. Kriege  Politische Aktionen  Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele Kunstwerke Epochen Webseiten Sprachen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein Helbig et al. ([Helbig]_PER et al.)OTH Mensch-ärgere-dich-nicht, Halo Mona-Lisa Barock, Romantik (auch Neubildungen: "Neuzeit")) www.ebay.de, google, www Hochdeutsch, Englisch	
	Buch-, Filmtitel etc. Kriege  Politische Aktionen  Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele Kunstwerke Epochen Webseiten	Faust, Schlaflos in Seattle  Zweiter Weltkrieg  7. Bremer Protesttag gegen Diskriminierung  Agenda 21  Euro  Dow Jones, Dax  SZ-Magazin 41/07  Deutsch, Latein  Helbig et al. ([Helbig]_PER et al.)OTH  Mensch-ärgere-dich-nicht, Halo  Mona-Lisa  Barock, Romantik (auch Neubildungen: "Neuzeit"))  www.ebay.de, google, www	
OTHderiv –	Buch-, Filmtitel etc. Kriege  Politische Aktionen  Projektnamen Währungen Marktindex Reihennummerierungen Sprachen Buchtitel mittels Autor Spiele Kunstwerke Epochen Webseiten Sprachen	Faust, Schlaflos in Seattle Zweiter Weltkrieg 7. Bremer Protesttag gegen Diskriminierung Agenda 21 Euro Dow Jones, Dax SZ-Magazin 41/07 Deutsch, Latein Helbig et al. ([Helbig]_PER et al.)OTH Mensch-ärgere-dich-nicht, Halo Mona-Lisa Barock, Romantik (auch Neubildungen: "Neuzeit")) www.ebay.de, google, www Hochdeutsch, Englisch	

Keine NE	Datums- und Zeitangaben	Montag, April, Feiertage	
	Maßeinheiten	Meter, Liter	PERderiv: <del>Celsius</del>
	Religionen	Christentum, muslimisch	Götternamen
	Tiernamen	Gepard, Schlange	

Bezeichner/Fachwörter	Phosphat, Geodäten, Ikonen	Produkt- namen: <del>Aspirin</del>
Himmelsrichtungen	südlich, Norden	
Mottos	Carpe diem!	
Titel/Anrede	Frau, König	
	Gott	Bestimmte Götter: <del>Vishnu</del>
Dynastien und Geschlechter	Habsburger, Wittelsbacher	Stämme: <del>Moari</del>
Politische Strömungen	Kommunismus, Sozialismus	

## Regeln

Regel	Beispiele	NE
Klassen werden unabhängig von der semantischen Rolle im Kontext vergeben. ABER: Grammatische Hinweise entscheiden.	Nils Petersen geht  zu [Bremen]ORG  nach [Bremen]LOC  Die [Wolfsburger]LOCderiv entwickeln Spitzentechnik. (eigentlich VW in Wolfsburg)	V
Marken- oder Erfindernamen die als Universalbegriffe genutzt werden werden nicht als NEderiv markiert	Pampers, Tempo, Teddybär, Celsius, Watt, olympische	*
Klassen	Gepard-Klasse, A-Klasse	*
Ableitungen NEderiv werden nur	die [decartessche] <b>PERderiv</b> Philosophie	<b>/</b>
dann annotiert, wenn sie den Stamm mit einer NE teilen.	die anglikanische Kirche	*

## Formen

Regel	Beispiele	NE
abgetrennt Kompositionsglieder	in [West-] <b>LOC</b> und ganz besonders in [Ost-Berlin] <b>LOC</b> [Adenauer-] <b>ORG</b> und [Böll-Stiftung] <b>ORG</b>	<
Ortsteile	[West-Afrika] <b>LOC</b> [Nord-Berlin]LOC	<
Adelstitel	Herr [von [ <b>Hohenzollern</b> ] <b>LOC</b> ]PER Queen [Elisabeth]PER	<
Gesetze	Art . 2 Nr. 18	*
Abkürzungen	Amis, Sowjets	*

## Einzelfälle

Begriff	Semantische Klasse	Semantische Subklasse	Kommentar
Bundesliga	ORG	Organisationen	
Creditreform-Mittelstandsindex	ORGpart	Unternehmen	
Darmstadtium	ORG/LOC	Veranstalter / Veranstaltungsort	kontextabhängig
Bibel	ОТН	Buchtitel	
Hotel Bellevue	ORG	Hotels	
Milchstraße	LOC	Himmelskörper	wie Planeten
Evangelium	keine NE	Bezeichnung	
Gott		Bezeichnung	
Polizei & Feuerwehr		Gruppen	

Indianer	Bezeichnung	einzelne Stämme : ORG
Bundesregierung	Bezeichnung	
Weltmeisterschaft	Bezeichnung	Bestimmte WM, zB. Fußball-WM: ORG
ISBN	Bezeichnung	

## **Bibliografie**

- Schiller, Anne; Teufel, Simone; Stöckert, Christine; Thielen, Christine (1999): Guidelines für das Tagging deutscher Textkorpora mit STTS. Technical Report. University of Stuttgart; University of Tübingen. BibTex
- ➤ Telljohann, Heike; Hinrichs, Erhard W.; Kübler, Sandra; Zinsmeister, Heike; Beck (2012): Stylebook for the Tübingen Treebank of Written German (TüBa-D/Z). Seminar für Sprachwissenschaft. Universität Tübingen, Germany. <a href="http://www.sfs.unituebingen.de/resources/tuebadz-stylebook-1201.pdf">http://www.sfs.unituebingen.de/resources/tuebadz-stylebook-1201.pdf</a>. BibTex
- ➤ MUC-6 Named Entity Task Definition: http://cs.nyu.edu/faculty/grishman/NEtask20.book\_1.html

## **Beispiele**

